# BI25M Machine learning

ANNA BRUNSKOG

## Teoretiska frågor

1. *All data i Python representeras av objekt. I Python består varje objekt av tre grundläggande delar. Vilka är dessa delar? Beskriv varje del kort.*

- **Identity** = Är objektets "plats i minnet", det är unikt för varje objekt och har ett eget id-nr som kan kan hitta med id().
- **Type** = Beskriver vilken datatyp objektet har, (int, str, list osv.). Datatypen i sin tur avgör vilka metoder och operationer man kan göra med objektet. Python tolkar/bestämmer själv datatypen, men det går att "tvinga" fram en ändring om behovet finns.
- **Value** = Är värdet/innehållet i objektet. Det kan vara tal om det är int, text om det är str, [1,2,3] om det är en list, osv, osv.

2. *Förklara skillnaden mellan mutabla och immutabla objekt i Python och ge exempel på varje.*

- **Immutabla** = oföränderliga
  Dessa kan inte ändras efter att de har skapats.
  Exempel: tuple, frozenset (även str är egentligen ett immutable objekt)
  För att "ändrar" dem behöver man skapa ett nytt objekt.
- **Mutabla** = föränderliga
  Dessa kan ändras utan att man skapar ett nytt objekt.
  Exempel: list, dict, set

3. *3. Vad är ett set i Python? Vilka egenskaper särskiljer det från listor? Ge ett praktiskt exempel där det är mer effektivt att använda ett set än en lista.*
   Ett set är en samling unika värden som lagras utan att vara i en speciell ordning. De skapas med måsvingar { }. De skiljer sig från listor, som då har sina värden i ordning, skapas med parantes ( ). Ett set är t.ex mer effektivt när man vill se om ett visst värde finns i objektet.

4. *Förklara vad en loop är och ge exempel på när den används.*
   En loop är en kod som använda för att uppreda en annan del av koden flera gånger, dvs återupprepar den. Man kan använda loopar för både enkla och mer komplicerade saker. En enkel variant är t.ex att skriva ut värdena i en lista eller

skapa nya listor, men de kan egentligen göras hur komplicerade som helst med loopar i loppar för alla möjliga olika användningsområden (t.ex ett system som varje kväll går igenom alla kundbeställningar, och för varje beställning kontrollerar varje enskild produkt mot lagersaldo, uppdaterar lagret, markerar leveransstatus och skickar notifieringar beroende på olika villkor.)

5. *Vad är en klass och hur skiljer sig en instans från själva klassen?*
   ”En klass kombinerar data och funktion” (– från lär dig Python från grunden), så det är som en mall eller en ritning medan en instans är ett konkret objekt som skapas från klassen. En klass kan t.ex vara en hund, medan objektet är en Border Collie.

6. *Vad är en funktion och varför använder programmerare dem? Förklara skillnaden mellan en funktion med returvärde och en som inte returnerar något*.
   En funktion är en bit kod som man sen kan återanvända så att man slipper skriva den flera gånger. Om funktionen skapar ett returvärde , så kan vi använda det värdet vidare. Om den inte returnerar något så får vi ett svar på just vår fråga, men inte mer.

7. *Förklara begreppet parameter jämfört med argument Python*.
   En parameter är en variabel som användas i en funktion. För parametern anges sen ett argument som motsvarar värdet på parametern just då. Parametern förblir konstant medan argumenten kan variera eller ”utvecklas”. För parametern anges vilka argument som är tillåtna positionsargument, nyckelordsargument eller bägge två.

8. *Titta på följande video om R: R Programming. Vad är skillnaden mellan R och Python?*
   R och Python är båda språk som används för dataanalys och maskininlärning, men de har lite olika fokus. R skapades främst för statistik och används mycket inom forskning och akademi. Python är mer allmänt och används inte bara för dataanalys utan även för webbutveckling, appar och AI.
   Man kan säga att R är mer specialiserat på statistik och färdiga analysverktyg, medan Python är bredare och mer flexibelt och därför vanligt i industrin. Båda kan göra liknande saker inom dataanalys, men Python har blivit mer dominerande inom maskininlärning.

9. *Kalle ska bygga en ML-modell och delar upp sin data i ”Träning”, ”Validering” och ”Test”, vad används respektive del för?*
   Träningsdata används för modellen att lära sig data på. Validering används för att kunna välja modell och hyperparametrar och testdata används för att slutligen utvärdera modellen. Testdatan skall var osedd och får inte påverka modellvalet.

10. *Julia delar upp sin data i träning och test. På träningsdatan så tränar hon tre modeller; ”Linjär Regression”, ”Lasso regression” och en ”Random Forest modell”. Hur skall hon välja vilken av de tre modellerna hon skall fortsätta använda när hon inte skapat ett explicit ”valideringsdataset”?*
    Om hon inte har valideringsdata så kan hon i stället göra en korsvalidering. Utifrån resultatet från varje modell på Accuracy, Precision/Recall och F1-score göra ett val för vilken modell hon ska gå vidare med.

11. *Vad är ”regressionsproblem? Kan du ge några exempel på modeller som används och potentiella tillämpningsområden?*
    Regressionsproblem handlar om att kunna förutse ett värde utifrån data som är linjär, dvs att där y förändras proportionellt mot x. En linjär modell behöver inte betyda att grafen är en helt rak linje utan den kan också vara polynom så länge den är linjär i sina parametrar.

12. *Hur kan du tolka RMSE och vad används det till.*
    RMSE betyder Root Mean Square Error. Den använda för att mäta hur långt ifrån de riktiga värdena modellens förutsägelser. RMSE användas för att bedöma hur stora fel modellen gör. Lågt RMSE värden ligger nära de verkliga värdena, högt RMSE visar att modellen gör större fel. RMSE ligger nära standardavvikelse tankemässigt och matematiskt och man kan säga att RMSE är standardavvikelsen för modellens fel.

13. *Vad är ”klassificieringsproblem? Kan du ge några exempel på modeller som används och potentiella tillämpningsområden?*
    Klassificeringsproblem om att i stället för att linjärt förutsäga värden så försöker man förutse vilken grupp/kategori (=klass) viss data tillhör. Exempel på detta kan vara om ett mail är spam eller inte, om en person är sjuk eller frisk eller mer komplicerat om en bild föreställer t.ex en hund, katt eller en siffra.

14. *Vad är en ”Confusion Matrix”*
    En Confusion Matrix visar visuellt hur väl en modell presterar. Den jämför sanna värden med predikterade och lägger in dem i en matris. Matrisen visar true positiv, true negative, false positive och false negativ och kan användas för att förstå var modellen gör fel.

15. *Vad är K-means modellen för något? Ge ett exempel på vad det kan tillämpas på.*
    K-means är ”icke-övervakad inlärningsmodell” vilket innebär att den grupperar data i olika kluster utan att klustrena har definierats i förväg Man använder den när man vill hitta naturliga grupper utan att i förväg veta hur man vill kategorisera dem. Exempel på användning är t.ex kundkategorisering, musikrekommendationer, sjukdomsmönster hos patienter etc. Det kan också användas för att se om någonting sticker ut från mängden och inte ”passar in” inom respektive kluster. Detta använda för att hitta fel inom tillverkningsindustrin eller för att t.ex hitta bedrägeriemönster bland transaktioner.

16. *Förklara (gärna med ett exempel): Ordinal encoding, one-hot encoding, dummy variable encoding.*
    Ordinal encoding = innebär att kategorier får nummer. Den fungerar bra när kategorierna har en naturlig ordning (t.ex utbildningsnivå) och fungerar bra i t.ex Decision Tree och Random Forest.
    One-hot encoding = skapar kolumner och använda när kategorier saknar inbördes ordning (t.ex färger eller länder). Den fungerar bra i Random Forest och Decsison Tree men kan också användas i linjära modeller.
    Dummy = som one-hot men en kolumn tas bort, den borttagna kategorin blir referens. Dummy använda vid framför allt i linjär regression.

17. *Göran påstår att datan antingen är ”ordinal” eller ”nominal”. Julia säger att detta måste tolkas. Hon ger ett exempel med att färger såsom {röd, grön, blå} generellt sett inte har någon inbördes ordning (nominal) men om du har en röd skjorta så är du vackrast på festen (ordinal) – vem har rätt?*
    Julia har rätt. Färger är ofta nominala, dvs utan inbördes ordning, men om färgerna sorteras t.ex efter hur vackra de är eller pris på akrylfärgstuber så blir de ordinala.

18. *Vad är skillnaden mellan parametrar och hyperparametrar i en maskininlärningsmodell? Ge ett exempel på varje och förklara varför de inte kan optimeras på samma sätt.*
    Parametrar är de värden som modellen lär sig från datan under träningen, När modellen tränas försöker den hitta de parametrar som minimerar fel.
    Hyperparametrar är inställningar som man väljer innan träning och styr sedan hur modellen ska tränas och hur komplex den får vara.
    Ett exempel på en parameter är koefficienterna i en linjär regressionsmodell, vilka beräknas direkt från datan. Exempel på hyperparametrar är maxdjup i ett beslutsträd eller antalet träd i en Random Forest. Parametrar kan optimeras

direkt genom matematiska optimeringsmetoder eftersom de ingår i modellens funktion. Hyperparametrar kan däremot inte estimeras på samma sätt, utan måste utvärderas genom att testa olika kombinationer, exempelvis med hjälp av cross-validation och metoder såsom Grid Search.

19. *Förklara skillnaden mellan overfitting och underfitting i en maskininlärningsmodell. Beskriv även hur man kan upptäcka respektive åtgärda dem.*
    Overfitting uppstår när en modell är för komplex i förhållande till datamängden och därför anpassar sig alltför väl till träningsdatan, inklusive slumpmässiga variationer och brus. Detta leder ofta till mycket låg felmarginal på träningsdata men betydligt högre fel på testdata, eftersom modellen har sämre förmåga att generalisera ny data.
    Underfitting uppstår när modellen är för enkel för att fånga de underliggande mönstren i datan. I detta fall blir felet högt både på träningsdata och testdata, eftersom modellen inte lyckas beskriva sambandet på ett tillräckligt bra sätt.
    Overfitting kan upptäckas genom att jämföra modellens prestanda på tränings- och testdata, och kan motverkas genom exempelvis regularisering, begränsning av modellens komplexitet eller användning av mer data. Underfitting kan åtgärdas genom att öka modellens komplexitet eller genom att använda en mer avancerad modell.

## Självutvärdering

*1. Har något varit utmanande i kursen/kunskapskontrollerna? Om ja, hur har du hanterat det?*

För mig som akademiker så har programmeringen i sig varit den största utmaningen. Den teoretiska delen och processerna tycker jag har varit både inspirerande och intressant.

För att hantera programmeringen har jag använt mig mycket av kod-exemplen i boken och även använt Chat-GPT, både för att ge exempel men framför allt för att förklara så att även jag förstår, (När jag kom till Streamlit måste jag erkänna att Chat-GPT fick göra det mesta av kodningen och inte fokusera lika mycket förklarande).

*2. Vilket betyg anser du att du ska ha och varför?*

Jag hoppas att jag får ta mig friheten att inte svara på den frågan. Precis som vi inte använder test-datan i våra modeller så vill jag inte att utvärderingen ska vara färgad av min egen reflektion.

*3. Något du vill lyfta fram till Terese?*

Det har varit en väldigt givande kurs. Framför allt uppskattar jag möjligheten att både få en överblick över vad ML/AI egentligen är och att få dyka ned i att göra egna modellutvärderingar att testa teorierna på. Det var kul med Streamlit för då blev allting mycket mer verkligt.  Jag är väldigt tacksam att vi äntligen har fått kurslitteratur att använda parallellt med föreläsningarna.

## Inlämnat: 2026-03-04